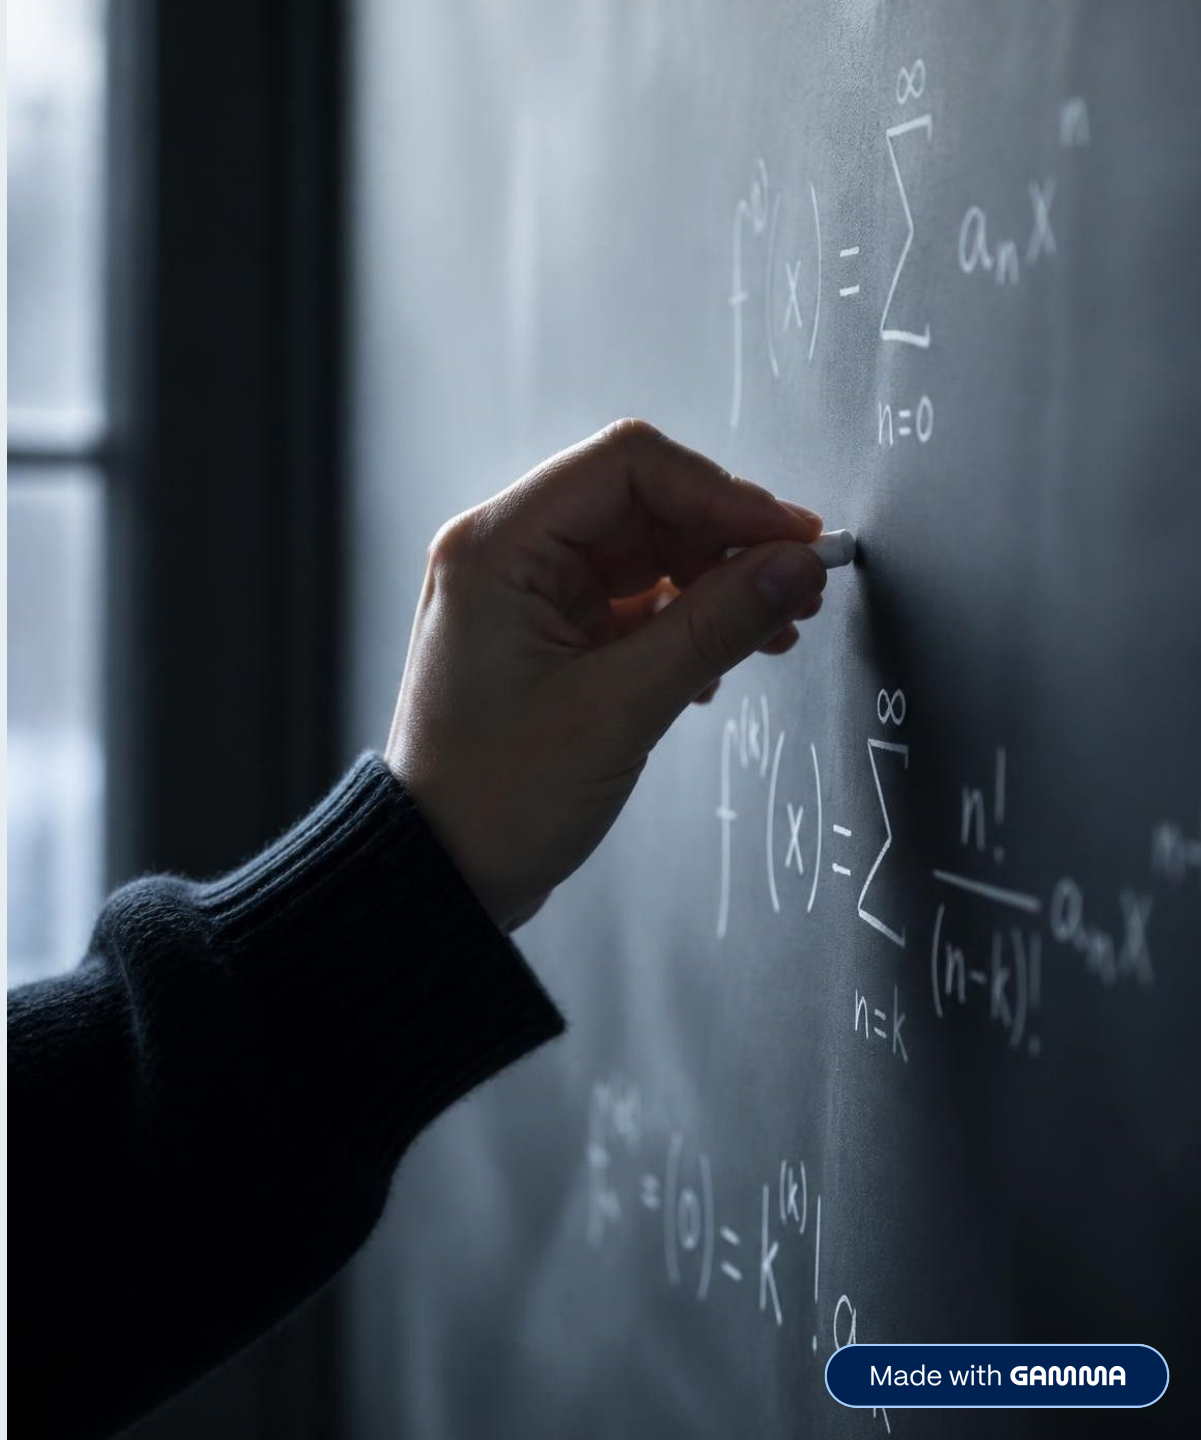
ТЕХНОЛОГИИ И ФРОНТИРЫ В ОБЛАСТИ КОМПЬЮТЕРНЫХ НАУК

Логистическая регрессия в бинарной классификации

Модель, которая учится отвечать «да» или «нет». Разберём, как она работает и как её проверять.



Made with GAMMA

ФУНКЦИЯ АКТИВАЦИИ

Сигмоида переводит линейный прогноз в вероятность

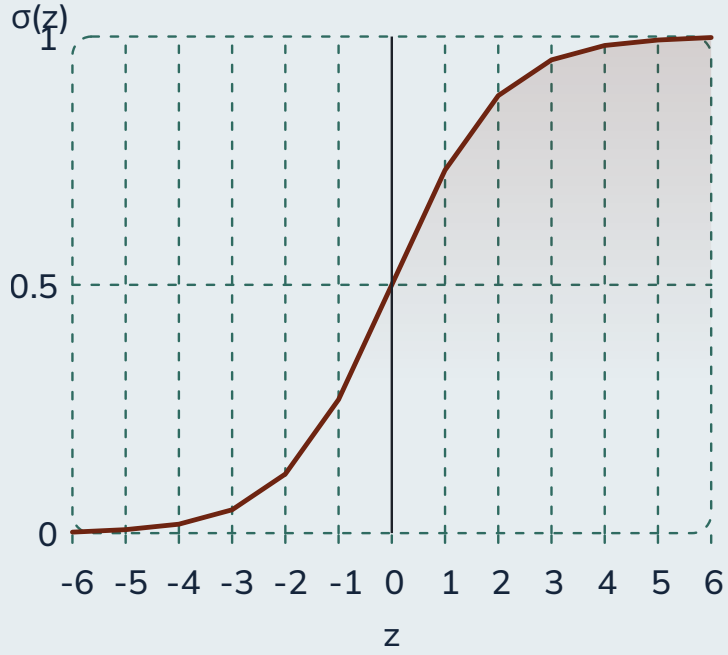
Сначала считаем взвешенную сумму признаков:

$$z = \beta_0 + \beta_1 x_1 + \cdots + \beta_p x_p$$

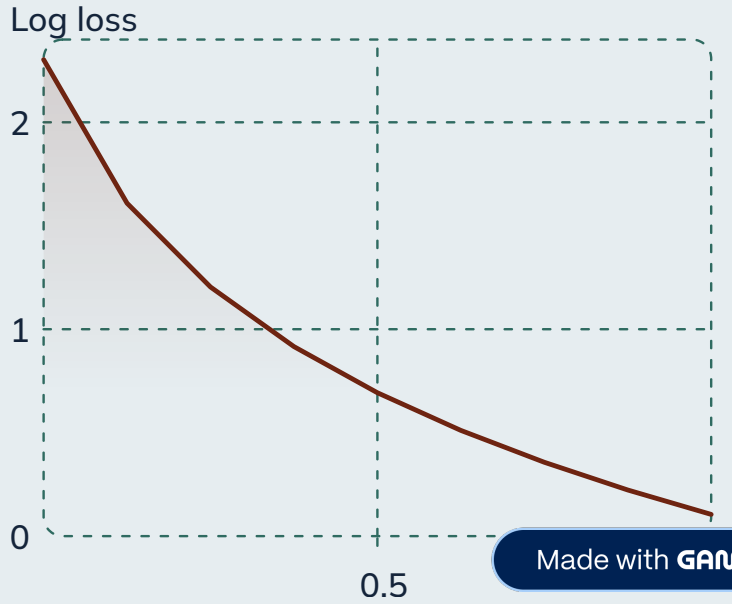
Затем сжимаем результат в диапазон от 0 до 1:

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

Ответ всегда между 0 и 1. Его читают как вероятность того, что объект относится к классу 1: $P(y = 1 \mid x)$.



Log loss при y=1: -ln(p) для прогноза p



Made with GAMMA

ОПТИМИЗАЦИЯ И МЕТРИКИ

Матрица ошибок и основные метрики

Матрица ошибок

	Прогноз: 0	Прогноз: 1
Факт: 0	**TN**: верно отказали	**FP**: ложная тревога
Факт: 1	**FN**: пропуск	**TP**: верно нашли

Precision = TP/(TP+FP) · Recall = TP/(TP+FN) · F1 = 2·Precision·Recall/(Precision+Recall)

F1 — гармоническое среднее Precision и Recall; показывает их баланс

Порог решения

Порог 0,5 превращает вероятность в класс; порог меняют под цену ошибки.

Метрики оценки

Precision и Recall показывают, какие ошибки модель допускает чаще.

Made with GAMMA



ПРИМЕНЕНИЕ 01 · ФИНТЕХ

Кредитный скоринг ценит прозрачность

Вероятность невозврата

Модель считает, вернёт ли человек долг. Она учитывает доход, кредитную историю, стаж и сумму займа.

Вклад каждого фактора

Знак коэффициента показывает, помогает фактор или мешает. Величина показывает, насколько он важен.

Стандарт банков

Банки используют её, потому что можно объяснить каждый отказ заёмщику.

Made with GAMMA

ПРИМЕНЕНИЕ 02 · ЗДРАВООХРАНЕНИЕ

В медицине важны объяснимость и калибровка

1 Оценка рисков

Модель оценивает, насколько вероятна болезнь или осложнение по симптомам и анализам.

2 Отношение шансов (Odds Ratio)

e^{β_j} показывает, во сколько раз меняются шансы исхода, если признак растёт на единицу.

3 Калибровка важнее Accuracy

Если модель даёт 0,8, то из 10 таких пациентов осложнение появится у 8.



Made with GAMMA

ПРАКТИЧЕСКИЕ НЮАНСЫ

Модель нужно правильно настроить

Линейная граница

Модель проводит прямую границу между классами. Сложные связи в данных она не видит без дополнительных признаков.

Похожие признаки и выбросы

Если признаки похожи, веса становятся нестабильными. Помогают отбор признаков и регуляризация.

Дисбаланс классов

Если событий мало, порог 0,5 плохо работает. Нужно выровнять веса классов и подобрать порог.

Вывод: качество данных сильно влияет на результат модели.

Made with GAMMA

Новые методы делают модель понятнее и надёжнее

A novel framework for enhancing transparency in credit scoring

PLOS ONE, 2024

Авторы предлагают использовать значения Шепли, чтобы понятнее объяснять решения модели в кредитном скоринге. Логистическая регрессия остаётся важной базовой моделью, а инженерия признаков повышает её практическую ценность.

Variable importance analysis with interpretable machine learning for fair risk prediction

PLOS Digital Health, 2024

Метод ShapleyVIC помогает оценивать важность признаков в клинических моделях и строить более понятные и справедливые прогнозы риска.

When Do Logistic Regression and Generalized Maximum Entropy Agree? Evidence from Simulation Studies

Journal of Modern Applied Statistical Methods

Авторы сравнивают логистическую регрессию и метод максимальной энтропии в сложных ситуациях: при мультиколлинеарности, редких событиях и выбросах.

Made with GAMMA



ГЛАВНЫЙ ВЫВОД

Простая модель остаётся эталонным инструментом

Простая математика

Понятные вероятности и простая функция потерь. Модель быстро обучается.

Осознанный баланс

Точность, скорость, понятность и контроль ошибок в разумном балансе.

Практический подход

Честные вероятности и порог под задачу важнее высокого Accuracy.

Made with GAMMA

Источники и литература

Scikit-learn: LogisticRegression	Как устроена модель и как её настраивают.
Scikit-learn: Metrics and scoring	Как измерять качество классификатора.
A novel framework for enhancing transparency in credit scoring: Leveraging Shapley values for interpretable credit scorecards	PLOS ONE, 2024
Variable importance analysis with interpretable machine learning for fair risk prediction	PLOS Digital Health, 2024
Integrating Explainable AI with Polynomial Analytics to Enhance Credit Scoring Model Compliance	Institute of Statistical Science, Academia Sinica, 2024

Made with GAMMA